

**JARINGAN SARAF TIRUAN:
PENGARUH HYPERPARAMETER PADA ARSITEKTUR
MULTI LAYER PERCEPTRON**



Vincent Michael Sutanto

16/398531/PA/17492

PROGRAM STUDI ILMU KOMPUTER
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA

2019


Pengantar

Uji coba dilakukan pada data MNIST berukuran 28 x 28 yang diratakan menjadi 1 dimensi berukuran 784 yang kemudian dimasukkan ke dalam multi layer perceptron. Dilakukan *classification task* yang memprediksi data MNIST (6000 data latih dan 1000 data validasi) ke dalam 10 kelas yang berbeda, dengan jumlah epoch sebesar 20 epoch.

Pada percobaan ini dilakukan pengubahan nilai **hyper-parameter** untuk mengetahui pengaruh dari hyper-parameter terhadap performa dari multi-layer perceptron


Hidden Layer

1 Hidden Layer




Pada percobaan 1 Hidden Layer didapatkan bahwa tingkat akurasi test mencapai 0.942, namun dari grafik terlihat bahwa akurasi dari train dan test terpaut jarak sekitar 0.06.

3 Hidden Layer




Pada percobaan 3 Hidden Layer didapatkan bahwa tingkat akurasi test mencapai 0.94, namun dari grafik terlihat bahwa akurasi dari train dan test terpaut jarak sekitar 0.06 seperti grafik 1 Hidden Layer, tetapi dengan fitting yang lebih baik (lebih rapat)

5 Hidden Layer




Pada percobaan 5 Hidden Layer didapatkan bahwa tingkat akurasi test mencapai 0.948. Dari grafik terlihat bahwa akurasi dari train dan test terlihat lebih rapat jika dibandingkan dengan 1 dan 3 Hidden Layer.




8 Hidden Layer

Pada percobaan 8 Hidden tingkat akurasi test rendah dari 5 Hidden Layer). bahwa akurasi dari train dan jika dibandingkan dengan 1,



Layer didapatkan bahwa mencapai 0.936 (Lebih Dari grafik juga terlihat test terlihat lebih rapat 3, dan 5 Hidden Layer.




Kesimpulan Hidden Layer

Dari percobaan yang dilakukan, jumlah Hidden Layer mempengaruhi fitting dari data training dan data uji, dimana semakin banyak jumlah Hidden Layer, fitting dari data training dan data uji semakin baik (yang paling terlihat berpengaruh adalah Hidden Layer mempengaruhi grafik data uji)

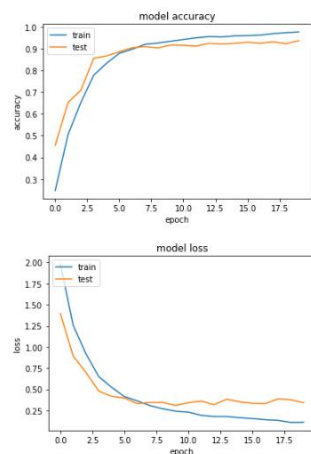
Node

64 Node




Percobaan dengan menggunakan 64 node menghasilkan tingkat akurasi sebesar 0.896, dengan grafik yang cukup baik (tidak underfit atau overfit). Namun terlihat bahwa penggunaan epoch sebesar 20 belum menghasilkan model yang konvergen untuk jumlah node 64

128 Node



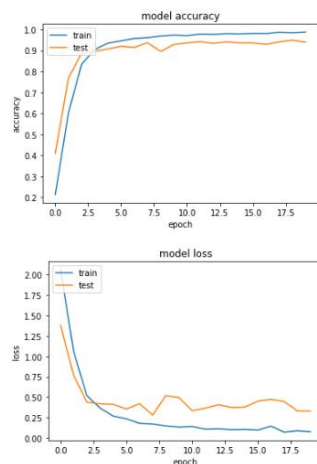
Percobaan dengan menggunakan 128 node menghasilkan tingkat akurasi sebesar 0.936, dengan grafik yang cukup baik (tidak underfit atau overfit, selisih training dan validation hanya sebesar 0.05). Terlihat juga dengan menggunakan 20 epoch model dengan jumlah node 128 sudah konvergen.

256 Node



Percobaan dengan menggunakan 256 node menghasilkan tingkat akurasi sebesar 0.937, dengan grafik yang cukup baik (tidak underfit atau overfit, selisih training dan validation hanya sebesar 0.05). Terlihat juga dengan menggunakan 20 epoch model dengan jumlah node 256 sudah konvergen dan konvergen lebih cepat dibandingkan dengan 128 node.

512 Node




Percobaan dengan menggunakan 512 node menghasilkan tingkat akurasi sebesar 0.94, dengan grafik yang cukup baik (tidak underfit atau overfit, selisih training dan validation hanya sebesar 0.04). Terlihat juga dengan menggunakan 20 epoch model dengan jumlah node 512 sudah konvergen dan konvergen lebih cepat dibandingkan dengan 128 dan 256 node.

Kesimpulan Node

Jumlah node pada percobaan yang dilakukan memperlihatkan bahwa semakin banyak node yang digunakan, semakin cepat pula model mengalami konvergensi. Dapat terlihat dimana pada 64 node model belum mengalami konvergensi dalam 20 epoch. Pada 128 node, model mengalami konvergensi pada epoch 8. Pada 256 node, model mengalami konvergensi pada epoch 4. Dan terakhir pada 512 node, model sudah mengalami konvergensi pada epoch 3.

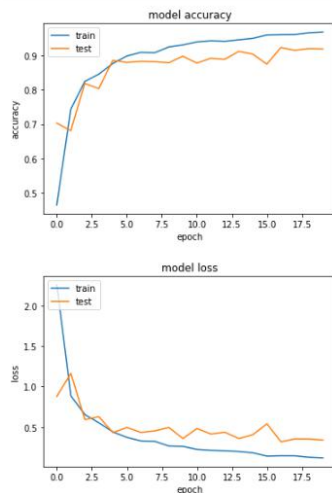
Activation Function

Relu



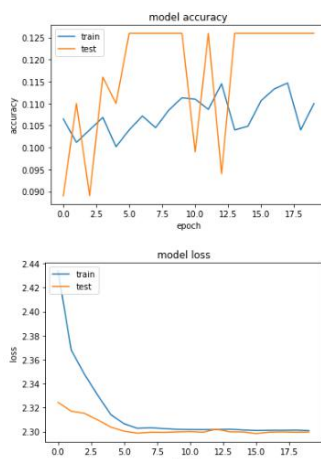
Penggunaan fungsi aktivasi relu menunjukan performa yang bagus pada dataset MNIST dengan arsitektur MLP. Dibuktikan dengan menghasilkan grafik yang konvergen dan nilai akurasi yang cukup tinggi yaitu sebesar 0.944

Tanh



Penggunaan fungsi aktivasi tanh menunjukkan performa yang bagus pada dataset MNIST dengan arsitektur MLP, namun tidak lebih baik jika dibandingkan dengan fungsi aktivasi relu. Grafik yang dihasilkan konvergen dengan selisih training-testing lebih besar daripada relu. Akurasi yang dihasilkan sebesar 0.918 pun tidak lebih baik daripada fungsi aktivasi relu

Sigmoid




Penggunaan fungsi aktivasi sigmoid bukan pilihan yang tepat pada dataset MNIST dengan arsitektur MLP. Akurasi yang dihasilkan hanya sebesar 0.126 dengan grafik yang tidak konvergen sedikitpun (cenderung overfit).

Kesimpulan Activation Function

Pada percobaan kali ini fungsi aktivasi relu menunjukkan kemampuan yang paling baik dibandingkan dengan tanh, sementara untuk sigmoid bukan pilihan yang tepat jika digunakan dalam arsitektur ini (diasumsikan karena representasi data yang tidak sesuai dengan yang seharusnya diterima oleh fungsi aktivasi sigmoid)

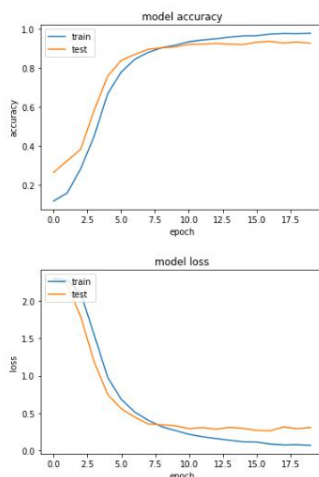
Learning-rate

0.1



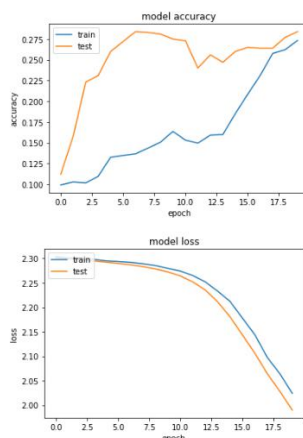
Learning rate sebesar 0.1 menghasilkan tingkat akurasi sampai dengan 0.945 dengan model yang dihasilkan konvergen (pada epoch 5 sudah konvergen), serta fitting yang dihasilkan model tergolong baik untuk percobaan sebesar 20 epoch.

0.01



Learning rate sebesar 0.01 juga menghasilkan tingkat akurasi sampai dengan 0.926 dengan model yang dihasilkan konvergen (pada epoch 8 sudah konvergen), serta fitting yang dihasilkan model tergolong baik untuk percobaan sebesar 20 epoch.

0.001



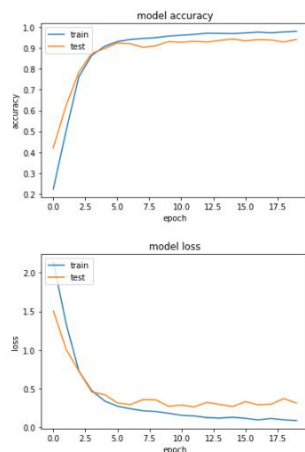
Learning rate sebesar 0.001 juga menghasilkan tingkat akurasi sebesar 0.284 dengan model yang dihasilkan overfit dan belum konvergen dalam 20 epoch.

Kesimpulan Learning Rate

Dari percobaan ditarik kesimpulan bahwa semakin kecil nilai Learning Rate, maka semakin banyak epoch yang dibutuhkan untuk model dapat mencapai konvergensi


Momentum

0.9



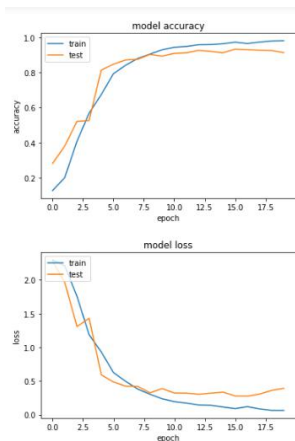
Percobaan dengan momentum sebesar 0.9 menghasilkan model yang konvergen pada epoch 5 dengan tingkat akurasi mencapai 0.942. Grafik yang disajikan juga menyampaikan bahwa model tidak overfit maupun underfit

0.5



Percobaan dengan momentum sebesar 0.5 menghasilkan model yang konvergen pada epoch 8 dengan tingkat akurasi mencapai 0.938. Grafik yang disajikan juga menyampaikan bahwa model tidak overfit maupun underfit

0.2




Percobaan dengan momentum sebesar 0.2 menghasilkan model yang konvergen pada epoch 10 dengan tingkat akurasi mencapai 0.914. Grafik yang disajikan juga menyampaikan bahwa model tidak overfit maupun underfit

Kesimpulan Momentum

Dari percobaan yang dilakukan ditarik kesimpulan bahwa nilai momentum dapat mempercepat konvergensi dari suatu model, dimana nilai momentum yang besar membuat model lebih cepat konvergen.


Initializer

Zeros




Initializer zero menunjukan performa yang dapat dikatakan buruk, dimana model tidak konvergen, overfit, dan tingkat akurasi hanya sebesar 0.126

Random-Normal



Inisialisasi bobot dengan Random-Normal menunjukkan hasil yang baik dimana model konvergen dengan fitting yang bagus, dan mencapai tingkat akurasi sebesar 0.93. Model konvergen pada epoch 5.

Glorot-Uniform



Sama seperti Random Normal, Inisialisasi bobot dengan Glorot-Uniform menunjukkan hasil yang baik dimana model konvergen dengan fitting yang bagus, dan mencapai tingkat akurasi sebesar 0.942. Model konvergen pada epoch 5.

Kesimpulan Initializer

Penggunaan initializer Zeros bukan pilihan yang baik pada percobaan ini. Sementara itu pemilihan initializer dengan Random-Normal dan Glorot-Uniform dapat direkomendasikan dimana model yang dihasilkan tergolong baik dan selisih tingkat akurasi antar keduanya juga tidak terpaut jauh